

ELLS (30 pts)

† Queremos minimizar una función:

- Imagina que la función es un aparato que recibes en tu mano y te da un número.

- Estás en un punto (Tu dominio)

y te pararon en un lugar inicial (x_0)

→ lo que estás buscando es el lugar donde tu aparato muestra el número más chico

† Búsqueda Local:

- Primero, observa que tu aparato te da información de cómo cambian los valores que salen en puntos a tu alrededor (Grad) y de la forma de la función en el punto en el que estás (Hess)

- Decides en función la mejor dirección para moverte y buscar un valor más chico

- Cuando gatiens la dirección, a hora decides el tamaño del paso que tomas.

- Para eso tienes formas de hacer: uno es dar un paso grande y ver si pasos más chicos son mejores. Luego decidir de tu paso.

— Si repites esto, te acercas a un punto mínimo, las formas como decides la dirección y el paso modifican la velocidad que te acercas.

+ Algoritmo de región de confianza:

- Ahora para decidir hacia donde y cuánto caminas, dibujas una bolita al rededor tuyo.

- Ahora sólo te importará irte al lugar donde tu aparato saca el número más chico en tu bolita.

- No te puedes parar en cada punto de la bolita. Esto sería muy tardado.

- En foncos con la información de Hess y Grad
que te da tu aparato intantas Imagínate
cómo ser los números de tu aparato en la
bolita.

- Haces un "modelo" que es como un bowl para tu
bolita y das el paso al lugar más profundo
de ese bowl en tu bolita.

- Haciendo esto y repitiendo, te vas
acercando al lugar donde tu aparato. Sacas el
número más chiquito. Las formas en las
que haces tu bowl, y dibujas la bolita
cambian que son exitosamente te acercas
a un mínimo.

Dem (30 puntos)

$$f(x) = \frac{1}{2} x^T Q x - b^T x$$

$$f(x + \alpha p_k) = \frac{1}{2} (x + \alpha p_k)^T Q (x + \alpha p_k) - \nabla f^T (x + \alpha p_k)$$

Nótese que como $f(x)$ es Cuadrático, su
aproximación de Taylor de segundo orden es
Exacta \Rightarrow

$$f(x + \alpha p_k) = f(x) + \nabla f^T \alpha p_k + \frac{1}{2} \alpha p_k^T Q \alpha p_k$$

min
 α $f(\alpha) = f(x) + \nabla f^T \alpha p_k + \frac{1}{2} \alpha^2 p_k^T Q p_k$

C.P.O

$$f'(\alpha) = 0$$

$$\nabla f^T p_k + \alpha p_k^T Q p_k = 0$$


$$\alpha p_k^T Q p_k = - \nabla f^T p_k$$

$$\alpha = \frac{- \nabla f^T p_k}{p_k^T Q p_k}$$

□

3. El problema de las Cámaras

Tenemos N Cámaras, M Crímenes,
Ambos son conjuntos de puntos en el plano:



¿Cuál es la pos. Óptima de
las Cámaras para cubrir
los crímenes?

→ Enfoque Elegido:

Función costo: $\min \max_{i,j}$ or

$$F(\vec{c}) = \underbrace{\sigma \sum_{i=1}^N \sum_{j=1}^M d(c_i, x_j)}_{\text{Cámaras}} + \underbrace{\sigma \sum_{i=1}^N \sum_{\substack{j=1 \\ i \neq j}}^M d(c_i, c_j)}_{\text{Crímenes}}^{-2}$$

En Este caso se aparece una
Menor distancia entre Cámaras y Crímenes y Una Mayor
distancia entre Cámaras.

Decidir utilizar esta función, ya que a pesar de tener singularidades cuando $C_i = C_j$, $i \neq j$.

Es continua y suave en cualquier otro caso, lo que permite utilizar los algoritmos vistos. Entonces.

Esto no es cierto para funciones distintas que pense como:

$$F(\vec{C}) = \sum_{i=1}^N \min_j d(C_i, x_j)$$

o

$$F(\vec{C}) = \sum_{i=1}^N \sum_{j=1}^M d(C_i, x_j)^2 \prod_{\{x_j \in B_\delta(C_j)\}} + C \prod_{\{x_j \notin \bigcup_{i=1}^N B_\delta(C_i)\}}$$

Ninguna de Estas es suave

Por otro lado

$$F(\vec{C}) = \sum_{i=1}^N \sum_{j=1}^M d(C_i, x_j)^2 = \sum_{i=1}^N \sum_{j=1}^N d(C_i, C_j)^2 \quad \text{No es Acotada por Alojo.}$$